LAPORAN TUGAS 2 SMART FARMING DASHBOARD

Mata Kuliah Big Data dan IoT

Ananda Churriyah R. **23082010240**

Kelas :

Paralel B

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PEMBANGUNAN "VETERAN" JAWA TIMUR

2026

Menunduh data pada kaggle

Import Library & Load Dataset

Pada langkah pertama dalam menganalisis data, kita perlu mengimpor pustaka yang diperlukan. Pustaka seperti Pandas, NumPy, dan Matplotlib sangat penting karena mereka memberikan alat dan fungsi untuk membantu kita dalam mengatur data serta membuat grafik. Setelah mengimpor pustaka, kita akan memuat dataset yang ingin kita teliti. Ini biasanya dilakukan dengan menggunakan fungsi seperti pd. read_csv() untuk file CSV atau pd. read_excel() untuk file Excel. Memuat dataset dengan benar sangat penting karena kesalahan saat memuat dapat menyebabkan masalah dalam analisis secara keseluruhan.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# load dataset
df = pd.read_csv("smart_farming_sensor_data.csv")

# lihat data awal
df.head()
```

	crop ID	soil_type	Seedling Stage	MOI	temp	humidity	result
0	Wheat	Black Soil	Germination	1	25	80.0	1
1	Wheat	Black Soil	Germination	2	26	77.0	1
2	Wheat	Black Soil	Germination	3	27	74.0	1
3	Wheat	Black Soil	Germination	4	28	71.0	1
4	Wheat	Black Soil	Germination	5	29	68.0	1

EDA (Exploratory Data Analysis)

EDA merupakan tahap penting dalam analisis data yang memungkinkan kita menjelajahi dataset secara mendalam. Tujuannya adalah untuk memahami susunan data, menemukan pola, mengenali anomali, dan mendapatkan gambaran awal mengenai data. Selama EDA, kita dapat menggunakan berbagai cara seperti visualisasi (contohnya, histogram, plot kotak) dan statistik deskriptif. Dengan demikian, kita dapat mengenali variabel yang paling berpengaruh dan memahami hubungan antara variabel-variabel tersebut. EDA juga membantu kita merencanakan langkah-langkah analisis selanjutnya.

Statistik dasar

Pada bagian ini, kita menghitung statistik dasar yang memberikan gambaran umum tentang data. Statistik dasar mencakup rata-rata, median, modus, dan deviasi standar. Rata-rata memberi tahu kita nilai tengah dari data, sedangkan median menunjukkan nilai yang membagi data menjadi dua bagian yang sama. Modus adalah nilai yang paling sering muncul. Deviasi standar membantu kita memahami seberapa jauh data menyebar dari rata-ratanya. Dengan mengetahui statistik dasar ini, kita dapat memperoleh gambaran awal mengenai distribusi data dan apakah data tersebut cenderung normal atau memiliki pola distribusi yang berbeda.

```
df.describe()
```

	MOI	temp	humidity	result
count	16411.000000	16411.000000	16411.000000	16411.000000
mean	43.695387	28.832612	63.487752	0.516178
std	27.160254	9.701465	22.630965	0.621691
min	1.000000	13.000000	15.000000	0.000000
25%	21.000000	20.000000	44.000000	0.000000
50%	41.000000	28.000000	69.200000	0.000000
75%	64.000000	37.000000	84.000000	1.000000
max	100.000000	46.000000	91.000000	2.000000

Cek missing value

Nilai yang hilang atau missing value adalah masalah biasa dalam analisis data yang dapat mempengaruhi hasilnya. Maka dari itu, sangat penting untuk melakukan pemeriksaan menyeluruh terhadap kumpulan data untuk menemukan nilai-nilai yang hilang. Kita bisa memakai cara seperti isnull() dan sum() pada DataFrame untuk menghitung total jumlah nilai yang hilang di setiap kolom. Setelah menemukan nilai yang hilang, kita harus memikirkan cara terbaik untuk mengatasinya, apakah dengan menghapus baris tersebut, mengisi nilai yang hilang

dengan rata-rata, atau menggunakan metode imputasi yang lain. Menangani nilai yang hilang dengan benar sangat krusial untuk menjaga kualitas analisis.

```
df.isnull().sum()

                 0
crop ID          0
soil_type        0
Seedling Stage   0
MOI              0
temp             0
humidity         0
result           0
dtype: int64
```

Info dataset

Di bagian ini, kita akan melihat informasi dasar tentang dataset yang mencakup jumlah baris dan kolom, tipe data dalam setiap kolom, dan beberapa contoh data. Dengan menggunakan metode seperti info() dan head(), kita bisa mendapatkan pemahaman yang jelas tentang struktur dataset. Ini membantu kita memastikan bahwa data yang kita miliki sesuai dengan yang diinginkan dan apakah ada kolom yang memerlukan pemrosesan lebih. Memahami informasi dataset ini juga membuat kita lebih mudah merencanakan langkah-langkah pembersihan dan analisis berikutnya.

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 16411 entries, 0 to 16410
Data columns (total 7 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   crop ID         16411 non-null  object
 1   soil_type       16411 non-null  object
 2   Seedling Stage  16411 non-null  object
 3   MOI             16411 non-null  int64
 4   temp            16411 non-null  int64
 5   humidity        16411 non-null  float64
 6   result          16411 non-null  int64
dtypes: float64(1), int64(3), object(3)
memory usage: 897.6+ KB
```

Data Cleaning

Proses pembersihan data adalah langkah penting untuk memastikan bahwa data yang akan dianalisis itu akurat dan konsisten. Pada tahap ini, kita akan menemukan dan memperbaiki kesalahan dalam data, seperti duplikasi, kesalahan penulisan, atau nilai yang tidak

konsisten. Misalnya, jika kita menemukan angka 'N/A' di kolom yang seharusnya berisi angka, kita perlu memutuskan apakah akan menghapus baris tersebut atau mengganti nilai itu dengan yang sesuai. Pembersihan data yang baik akan menghasilkan dataset yang lebih bersih dan siap untuk analisis yang lebih mendalam.

Handle Missing Value

Setelah menemukan nilai yang hilang, langkah berikutnya adalah mengatasi masalah tersebut. Ada berbagai metode yang bisa kita gunakan, seperti menghapus baris yang memiliki nilai hilang, mengisi nilai hilang dengan rata-rata atau median dari kolom itu, atau memakai teknik imputasi yang lebih rumit seperti K-Nearest Neighbors (KNN) untuk memperkirakan nilai yang hilang. Pilihan metode tergantung pada jumlah nilai yang hilang dan karakteristik data itu sendiri. Menangani nilai yang hilang dengan baik sangat penting untuk menghindari bias dalam analisis.

```
[43]
✓ 0s
df = df.dropna()
```

Handle Outliers (IQR Method)

Outliers adalah nilai yang sangat berbeda dari nilai lainnya dalam kumpulan data dan dapat berpengaruh besar pada hasil analisis. Untuk menemukan outliers, kita dapat menggunakan Metode IQR (Rentang Interkuartil). IQR dihitung dengan mengurangi kuartil pertama (Q1) dari kuartil ketiga (Q3). Nilai yang berada di luar rentang Q1−1. 5×IQR dan Q3+1. 5×IQR dianggap sebagai outliers. Setelah kita menemukan outliers, kita harus memutuskan apakah akan menghapusnya, menggantinya dengan nilai lain, atau mempertahankannya sesuai dengan konteks analisis.

```
[54]
✓ 0s
for col in df.select_dtypes(include=['float64','int64']).columns:

    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1

    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR

    df = df[(df[col] >= lower) & (df[col] <= upper)]
```

Format Datetime (jika ada kolom tanggal)

Jika kumpulan data kita memiliki kolom dengan informasi tanggal, sangat penting untuk memastikan bahwa formatnya benar agar kita dapat melakukan analisis berdasarkan waktu. Kita bisa menggunakan fungsi seperti pd. to_datetime()

untuk mengubah kolom yang berisi teks tanggal menjadi objek datetime. Dengan format yang tepat, kita dapat melakukan analisis terkait waktu, seperti menghitung tren musiman atau melihat perubahan data seiring berjalannya waktu.

```
[51]
✓ 0s
if 'timestamp' in df.columns:
    df['timestamp'] = pd.to_datetime(df['timestamp'])
```

Analisis Data

Setelah data dibersihkan dan disiapkan, kita bisa melanjutkan dengan analisis data yang lebih mendalam. Ini bisa meliputi berbagai teknik statistik, seperti analisis regresi, analisis kluster, atau analisis komponen utama (PCA). Selain itu, kita juga dapat memanfaatkan visualisasi data untuk menunjukkan hasil analisis. Tujuan analisis ini adalah untuk mendapatkan pemahaman yang lebih baik tentang data dan menjawab pertanyaan penelitian yang telah diajukan sebelumnya.

Correlation Heatmap

Heatmap korelasi adalah alat visual yang sangat bermanfaat untuk memahami hubungan antara variabel dalam kumpulan data. Dengan heatmap, kita dapat dengan mudah melihat variabel mana yang memiliki hubungan positif atau negatif dan seberapa kuat koneksi tersebut. Korelasi yang kuat bisa memberikan informasi tentang variabel mana yang mungkin saling mempengaruhi. Misalnya, jika kita menemukan bahwa dua variabel memiliki korelasi tinggi, kita

bisa lebih memperhatikan hubungan ini dalam analisis kita.

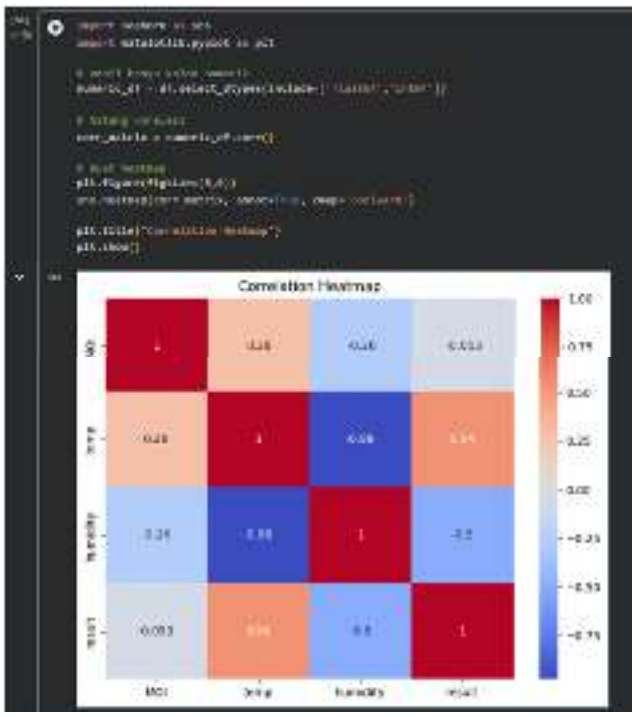

Time Series Trend (jika ada timestamp)

Jika dataset kita memiliki waktu yang tercatat, kita bisa menganalisis perubahan dari waktu ke waktu. Ini sangat membantu untuk melihat pola musiman atau perubahan yang terjadi dalam data seiring berjalannya waktu. Dengan menggunakan metode visual seperti grafik garis, kita bisa mengamati bagaimana nilai dari variabel tertentu berubah seiring berjalannya waktu. Analisis ini juga dapat berguna untuk membuat prediksi dan mengambil keputusan berdasarkan pola yang ditemukan.

```
[58]
✓ 0s
if 'timestamp' in df.columns:
    df.set_index('timestamp').plot(figsize=(10,5))
    plt.title("Sensor Data Trend Over Time")
    plt.show()
```

Simpan Cleaned Data

Setelah semua proses pembersihan dan analisis selesai, sangat penting untuk menyimpan data yang sudah bersih. Kita bisa menyimpan dataset dalam format yang tepat, seperti CSV atau Excel, sehingga bisa digunakan di masa depan. Menyimpan data yang sudah bersih membantu kita menghindari melakukan proses pembersihan yang sama lagi dan membuat kerja sama dengan tim lain yang mungkin memerlukan akses ke dataset

yang telah diolah menjadi lebih mudah.

```
[59]
✓ 0s
df.to_csv("cleaned_data.csv", index=False)

print("cleaned_data.csv berhasil disimpan")

... cleaned_data.csv berhasil disimpan
```

Data Governance – Data Quality Score

Data governance adalah praktik pengelolaan dan perlindungan data dalam suatu organisasi. Salah satu hal penting dari data governance adalah menilai kualitas data. Kita bisa menghitung skor kualitas data berdasarkan beberapa ukuran, seperti akurasi, kelengkapan, dan ketepatan waktu. Skor ini memberikan gambaran umum tentang seberapa baik data yang kita miliki dan apakah data tersebut memenuhi standar yang diperlukan untuk analisis. Dengan mengetahui kualitas data, kita bisa melakukan langkah-langkah yang diperlukan untuk memperbaiki masalah yang ada.

Total data

Di bagian ini, kita menghitung total data yang ada dalam dataset setelah proses pembersihan. Ini mencakup jumlah baris dan kolom yang tersisa setelah menghapus nilai yang hilang dan data yang tidak wajar. Memahami total data yang tersedia sangat penting karena ini akan mempengaruhi analisis yang akan kita lakukan selanjutnya. Jika jumlah data yang tersisa terlalu sedikit, hasil analisis mungkin tidak dapat dipercaya.

```
[60]
✓ 0s
total_cells = df.size
missing_cells = df.isnull().sum().sum()
non_null_cells = total_cells - missing_cells
```

Accuracy

Mengacu pada seberapa tepat data yang kita miliki. Data yang akurat adalah kunci untuk mendapatkan hasil analisis yang valid.

```
[63]
✓ 0s
accuracy = 1 - (missing_cells / total_cells)
accuracy

... np.float64(1.0)
```

Completeness

Menilai apakah semua informasi yang diperlukan ada dalam dataset. Data yang tidak lengkap dapat menyebabkan kesalahan dalam analisis.

```
[64]
completeness = non_null_cells / total_cells
completeness

np.float64(1.0)
```

Timeliness (data 30 hari terakhir)

Mengukur seberapa relevan data yang kita analisis, terutama jika kita melihat data dari 30 hari terakhir. Data yang tidak terkini mungkin tidak mencerminkan kondisi saat ini dan dapat mempengaruhi keputusan yang diambil berdasarkan analisis.

```
[65]
if 'timestamp' in df.columns:
    recent_data = df[df['timestamp'] >= df['timestamp'].max() - pd.Timedelta(days=30)]
    timeliness = len(recent_data) / len(df)
    timeliness
else:
    print("Kolom timestamp tidak tersedia")

Kolom timestamp tidak tersedia
```

Tampilkan Data Quality Summary

Dalam bagian ini, kita memberikan gambaran mengenai kualitas data yang mencakup semua ukuran yang telah kita hitung sebelumnya, seperti ketepatan, kelengkapan, dan kecepatan. Gambaran ini membantu kita dan orang-orang yang berkepentingan lainnya untuk mengetahui seberapa baik data yang kita miliki dan apakah ada bagian yang perlu peningkatan. Menyajikan gambaran mengenai kualitas data dengan jelas juga membuat komunikasi hasil analisis kepada orang lain menjadi lebih mudah.

```
[66]
print("Data Quality Score")
print("Accuracy:", accuracy)
print("Completeness:", completeness)

if 'timestamp' in df.columns:
    print("Timeliness:", timeliness)

Data Quality Score
Accuracy: 1.0
Completeness: 1.0
```

Dashboard pada power BI

Membuat dashboard menggunakan Power BI untuk menampilkan visualisasi data dan hasil analisis dengan cara yang interaktif. Dashboard memungkinkan pengguna untuk melihat data dengan cara yang lebih mudah, seperti menggunakan penyaring dan grafik yang dapat disesuaikan. Dengan dashboard yang baik, orang-orang yang berkepentingan dapat dengan cepat memahami informasi penting dan membuat keputusan berdasarkan data yang ditampilkan. Visualisasi yang menarik dan informatif dapat meningkatkan pemahaman serta keterlibatan pengguna.

Link embed report tidak dapat didapatkan karna butuh acc admin

Folder pada github

Link github: https://github.com/bitterivy/Big-Data-dan-IoT---Smart-Farming-Dashboard-dari-Sensor-IoT.git